

1 Variável Aleatória Continua

Até então, trabalhamos apenas com situações que envolvem variáveis aleatórias discretas.

Agora vamos trabalhar com valores contínuos para calcular probabilidades, um valor contínuo é aquele que pode assumir qualquer valor dentro de um intervalo, um valor discreto mediria por exemplo 0 ou 1, já a variável contínua pode assumir infinitos valores dentro desse intervalo, 0,01, 0,001, 0,0001 e assim por diante. Exemplos de variáveis contínuas são altura (1,75m), peso (65,5kg), temperatura (23,8°C), tempo (10,5s) e velocidade (80,2km/h).

Quando calculamos a probabilidade desses valores existe uma diferença:

Exemplo discreto:

- jogar um dado → resultado pode ser 1 até 6

Exemplo contínuo:

- medir o tempo de entrega → pode dar infinitos valores

Dessa forma não é possível listar tudo, porque tem infinitos valores.

Exemplo:

- altura: 1,70 ou 1,701 ou 1,7012...

A chance de dar um valor **exato** é praticamente zero

Então a pergunta muda:


Em vez de:

“qual a chance de dar 1,70?”

Você pergunta:

“qual a chance de estar entre 1,60 e 1,70?”

A probabilidade sempre está em um intervalo. E esse intervalo vira uma área no gráfico:



- O eixo horizontal (X) representa **altura das pessoas (em cm)**
- A curva azul mostra **como as alturas se distribuem na população**
- O pico da curva (lá no meio) → alturas mais comuns (por volta de 180 cm)
- As pontas → alturas mais raras

A parte **vermelha** representa pessoas com altura **entre 160 cm e 170 cm**.

Agora vem a ideia mais importante:

Essa área é a probabilidade. Aproximadamente 13,59% das pessoas estão nesse intervalo.

Para calcular a área utilizamos integral.

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

- $f(x)$ → é a curva (a “montanha”)
- a e b → são os limites (160 e 170)
- A integral → calcula a **área entre esses dois pontos, assim:**

$$P(160 \leq X \leq 170) = \int_{160}^{170} f(x) dx$$

No entanto não é necessário aplicar sempre cálculos integrais na mão, considerando que muitos estudos já foram feitos sobre esses casos de probabilidade e temos o conceito de distribuição normal ou gaussiana.

2 Distribuição Normal (Gaussiana)


A distribuição mais importante de todas é a dada pela função gaussiana e chamada de distribuição normal. Ela será a base para estatística e inferência e é fundamental para ciência e engenharia. A distribuição normal é definida em função da média e do desvio padrão:

$$P(X = x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$


Exemplo:

Um matemático belga do século XIX pôs na cabeça a idéia de descrever o "homem médio" e, por conta disso, mediu muitas variáveis. Na medida do perímetro torácico, ele encontrou valores de 34 a 48.


É possível identificar que a maior concentração de medidas está entre 40 e 41 polegadas, e podemos analisar a curva de distribuição desses valores:



Nessa curva podemos perceber que representa 100% da amostra ou população medida, e a maioria (68%) se concentra entre 38 e 44 polegadas, enquanto as exceções estão entre os demais valores.



Quando trabalhamos com variáveis contínuas os valores tendem a se comportar da mesma forma, assim conseguimos definir um padrão para calcular probabilidades. Dentre as muitas distribuições de frequências que têm a aparência da distribuição da figura anterior. Todas elas se aproximam de uma distribuição teórica chamada Distribuição Normal ou Distribuição de Gauss. Nenhuma distribuição empírica, no entanto, tem todas as características da distribuição normal. Mas o fato de pressupor que uma variável tem distribuição normal permite resolver muitos problemas em Estatística.




Essa curva representa a distribuição teórica de uma população infinita. Logo, o eixo das ordenadas não mostra a proporção de indivíduos em cada categoria porque não há como calcular proporções sobre um total que é infinito. Mas a curva abriga toda a população em estudo.

• A área total sob a curva é 1, ou seja, 100%, porque toda a população está sob a curva.
A distribuição normal fica definida quando são dados dois parâmetros:


- A média são o mesmo valor e representados pela letra grega μ (mi).
- E o desvio padrão, é representado pela letra grega σ (sigma).

Características da distribuição normal:


- A média, moda e mediana coincidem e estão no centro da distribuição.
- O gráfico da distribuição normal tem aspecto típico: é uma curva em forma de sino, simétrica em torno da média.
- Como a curva é simétrica em torno da média, 50% dos valores são iguais ou menores que a média e 50% dos valores são iguais ou maiores que a média.
- Todos os valores estão a no máximo 3 desvios padrões de distância da média.



- A média indica a posição e o desvio padrão indica o formato do gráfico.



A partir da identificação dessas características foi definida uma curva **Normal Padrão**, isto é, apenas uma curva normal com média igual a 0 e desvio padrão igual a 1.



A maioria das variáveis não cabem em uma curva Normal Padrão, mas podemos transformá-la para uma **Distribuição Normal Reduzida ou Padronizada**, onde transformamos a distribuição normal para uma média zero e variância 1. A variável que tem distribuição normal reduzida é chamada de variável reduzida ou padronizada e é indicada pela letra **Z**. Para isso utilizamos a fórmula abaixo, chamada de escala Z, que mede o número de desvios padrões distante da média.

$$Z = \frac{x - \mu}{\sigma}$$

- Z - valor da variável reduzida .
- X - valor original
- σ - desvio padrão
- μ - média

Podemos transformar qualquer variável aleatória X com distribuição normal de média e desvio padrão conhecidos em uma distribuição padronizada, as probabilidades associadas à distribuição normal reduzida são dadas em tabelas, o que torna mais fácil saber as probabilidades associadas a essa distribuição. Basta procurar na tabela.

Tabela das Distribuições Normal Padrão

z	0,00	0,01	0,02	0,03	0,04	0,05	0,06	0,07	0,08	0,09
0,0	0,5000	0,5040	0,5080	0,5120	0,5160	0,5199	0,5239	0,5279	0,5319	0,5359
0,1	0,5398	0,5438	0,5478	0,5517	0,5557	0,5596	0,5636	0,5675	0,5714	0,5753
0,2	0,5793	0,5832	0,5871	0,5910	0,5948	0,5987	0,6026	0,6064	0,6103	0,6141
0,3	0,6179	0,6217	0,6255	0,6293	0,6331	0,6368	0,6406	0,6443	0,6480	0,6517
0,4	0,6554	0,6591	0,6628	0,6664	0,6700	0,6736	0,6772	0,6808	0,6844	0,6879
0,5	0,6915	0,6950	0,6985	0,7019	0,7054	0,7088	0,7123	0,7157	0,7190	0,7224
0,6	0,7257	0,7291	0,7324	0,7357	0,7389	0,7422	0,7454	0,7486	0,7517	0,7549
0,7	0,7580	0,7611	0,7642	0,7673	0,7704	0,7734	0,7764	0,7794	0,7823	0,7852
0,8	0,7881	0,7910	0,7939	0,7967	0,7995	0,8023	0,8051	0,8078	0,8106	0,8133
0,9	0,8159	0,8186	0,8212	0,8238	0,8264	0,8289	0,8315	0,8340	0,8365	0,8389
1,0	0,8413	0,8438	0,8461	0,8485	0,8508	0,8531	0,8554	0,8577	0,8599	0,8621
1,1	0,8643	0,8665	0,8686	0,8708	0,8729	0,8749	0,8770	0,8790	0,8810	0,8830
1,2	0,8849	0,8869	0,8888	0,8907	0,8925	0,8944	0,8962	0,8980	0,8997	0,9015
1,3	0,9032	0,9049	0,9066	0,9082	0,9099	0,9115	0,9131	0,9147	0,9162	0,9177
1,4	0,9192	0,9207	0,9222	0,9236	0,9251	0,9265	0,9279	0,9292	0,9306	0,9319
1,5	0,9332	0,9345	0,9357	0,9370	0,9382	0,9394	0,9406	0,9418	0,9429	0,9441
1,6	0,9452	0,9463	0,9474	0,9484	0,9495	0,9505	0,9515	0,9525	0,9535	0,9545
1,7	0,9554	0,9564	0,9573	0,9582	0,9591	0,9599	0,9608	0,9616	0,9625	0,9633
1,8	0,9641	0,9649	0,9656	0,9664	0,9671	0,9678	0,9686	0,9693	0,9699	0,9706
1,9	0,9713	0,9719	0,9726	0,9732	0,9738	0,9744	0,9750	0,9756	0,9761	0,9767
2,0	0,9772	0,9778	0,9783	0,9788	0,9793	0,9798	0,9803	0,9808	0,9812	0,9817
2,1	0,9821	0,9826	0,9830	0,9834	0,9838	0,9842	0,9846	0,9850	0,9854	0,9857
2,2	0,9861	0,9864	0,9868	0,9871	0,9875	0,9878	0,9881	0,9884	0,9887	0,9890
2,3	0,9893	0,9896	0,9898	0,9901	0,9904	0,9906	0,9909	0,9911	0,9913	0,9916

Exemplo:




FIGURA 10.5 Probabilidade de ocorrer valor entre zero e $z = 1,25$.

2.1 $P(Z < 1,25) \approx 0,8944$

2.2 $P(Z < 0) = 0,5$

2.3 $P(0 < Z < 1,25) = 0,8944 - 0,5 = 0,3944$ ou **39,44%**

Exemplo:

A quantidade de colesterol em 100mL de plasma sanguíneo humano tem distribui normal com média 200mg e desvio padrão 20mg. Qual é a probabilidade de uma pessoa apresentar entre 200 e 225mg de colesterol por 100ml de plasma?

2.3.1 Para 200:

2.4 $Z = \frac{200 - 200}{20} = 0$


2.4.1 Para 225:

2.5 $Z = \frac{225 - 200}{20} = \frac{25}{20} = 1,25$

2.5.1 Da tabela:

- **2.6 $P(Z < 1,25) = 0,8944$**
- **2.7 $P(Z < 0) = 0,5$**
- **2.8 $P(0 < Z < 1,25) = 0,8944 - 0,5 = 0,3944$ ou **39,44%****

Todos os valores da curva já estão calculados na escala Z, então só consultamos na tabela.



Exercício

Seja X uma variável aleatória que representa a pressão sanguínea sistólica. Para a população de homens de 18 a 74 anos, a pressão sanguínea sistólica tem distribuição aproximadamente normal, com média igual a 129 milímetros de mercúrio (mm Hg) e desvio padrão de 19,8 mm Hg. Qual a probabilidade de que uma pessoa selecionada ao acaso dessa população tenha pressão sanguínea sistólica **maior que 167,8 mm Hg**?

Resolução

3 $\mu=129$

4 $\sigma=19,8$

5 Queremos: $P(X > 167,8)$

$$6 \quad Z = \frac{167,8 - 129}{19,8} = \frac{38,8}{19,8} \approx 1,96$$

7 $P(Z < 1,96) \approx 0,9750$

$$8 \quad P(Z > 1,96) = 1 - 0,9750 = 0,0250$$

9 Probabilidade = 0,025 ou 2,5%

10 Apenas 2,5% das pessoas têm pressão sistólica maior que 167,8 mm Hg.

11 Monte Carlo

Monte Carlo é um método probabilístico usado para prever valores incertos, como o lançamento de um dado, usando em geral um algoritmo e o alto poder computacional. É fortemente baseado na ideia de que uma repetição extremamente grande de um evento resultará em resultados próximos a esperança matemática. Observe alguns exemplos práticos de Monte Carlos aplicados na prática:

```
1 import random
2 sum = 0
3 for i in range(1000):
4     sum += random.randint(1, 6)
5 print(sum / 1000)
```

O código acima simula o lançamento de 1000 dados e tira a média. Cada vez que o código é rodado temos um valor diferente, contudo, todos próximos de 3.5. Claro que nesse caso é fácil saber qual o valor ideal apenas calculando a esperança matemática. Contudo, temos uma vantagem interessante em problemas complexos. Por exemplo, e se jogarmos 10 dados e queremos saber a probabilidade do maior valor jogado for um 6. Podemos fazer simplesmente um Monte Carlo:

```
1 import random
2
3 contador = 0
4
5 for experimento in range(1000):
6
7     dados = []
8
9     for i in range(10):
10         valor = random.randint(1, 6)
11         dados.append(valor)
12
13     if max(dados) == 6:
14         contador += 1
15
16 resultado = contador / 1000.0
17
18 print(resultado)
```

O resultado de uma execução aleatória foi de 0.848. E o resultado verdadeiro? Podemos calcular com certa dificuldade calculando a probabilidade de todos os dados serem menor que 6, ou seja, encontra a probabilidade do maior valor ser menor que 6:


$$P(X < 6) = (5/6)^{10} \approx 0.83849441711$$

E não se engane, calcular manualmente a probabilidade de, por exemplo, o quinto maior dado ser 4 é insanamente mais complexo do que o que foi feito acima. Usaremos o Monte Carlo para embasar e estudar algumas coisas com mais precisão.

Quanto mais simulações feitas, mais preciso é o Monte Carlo e mais tempo a simulação demora. No futuro discutiremos um pouco mais sobre as chances de falha e questões do tipo.

12 Teorema Central do Limite

Vamos supor que em uma determinada máquina de um difícil jogo em uma loja de conveniência observamos uma complexa distribuição de pontos que podem ir até 200. Grande parte dos jogadores não conseguem fazer nem 50 pontos. Mesmo assim, existe uma parte da população viciada no jogo que fica presa por volta dos 150 pontos. Ainda sim existem algumas poucas pessoas quem conseguem passar desses 150 pontos.



A função aleatória que descreve esse comportamento é a seguinte, embora ela pudesse ser qualquer coisa:

```
1  from random import uniform
2
3  def X():
4      L1 = uniform(0, 10)
5      L2 = uniform(0, 100)
6      if uniform(0, 1) < 0.01:
7          delta = uniform(0, 3)
8          return uniform(148 - delta, 152 + delta)
9      return uniform(0, L1 * L1) + uniform(0, L2)
```

Note que a média da distribuição X pode ser calculada por Monte Carlo e é aproximadamente 42.8. O desvio padrão é 31.33. Como pode ser calculado no código a seguir:


```
1  N = 1000000
2  X1 = [X() for _ in range(N)]
3  u = sum(X1) / N
4  print(u)
5
6  D = [(x - u) ** 2 for x in X1]
7  print(sqrt(sum(D) / N))
```

O dono da loja pensa em fazer um torneio desse popular jogo onde as equipes vão ser de 6 jogadores, onde o time vencedor será o que tiver maior média. Contudo, para evitar problemas com os viciados, os times serão escolhidos aleatoriamente dos inscritos no torneio. Assim, podemos montar uma distribuição

amostral. Uma distribuição amostral é a distribuição da variável aleatória da média de n (no caso 6) valores de uma outra variável aleatória X . Ou seja, está falando disso:

```
1 def Y():
2     n = 6
3     return sum([X() for _ in range(n)]) / n
```

O resultado é a seguinte distribuição, que lembra um pouco a distribuição normal. Ela é definitivamente uma distribuição contínua, pois existem muitos valores possíveis para uma média de 6 valores.




Algo muito interessante pode ocorrer se aumentarmos ou diminuirmos a quantidade de jogadores no time. Não apenas isso, vamos comparar a distribuição com uma gaussiana com média igual a média original e desvio padrão igual a, especificamente o desvio padrão original dividido pela raiz da quantidade de jogadores na amostra. Os resultados evidenciam o Teorema Central do Limite:

```
1 N = 100000
2 X1 = [Y(3) for _ in range(N)]
3 X2 = [Y(6) for _ in range(N)]
4 X3 = [Y(12) for _ in range(N)]
5 X4 = [Y(24) for _ in range(N)]
6
7 def gauss(x, mu, sigma):
8     return 1 / sqrt(2 * pi * sigma * sigma) * exp(-(x - mu) ** 2 / (2 *
9         sigma * sigma))
10
11 def gaussData(mu, sigma):
12     return [gauss(x, mu, sigma) for x in range(100)]
13
14 mu = 42.8
15 sigma = 31.33
16
17 fig, axs = plt.subplots(2, 2)
18 axs[0, 0].hist(X1, bins=range(100), density=True)
19 axs[0, 0].plot(gaussData(mu, sigma / sqrt(3)))
20 axs[0, 0].set_title("n = 3")
```

```

20
21  axs[0, 1].hist(X2, bins=range(100), density=True)
22  axs[0, 1].plot(gaussData(mu, sigma / sqrt(6)))
23  axs[0, 1].set_title("n = 6")
24
25  axs[1, 0].hist(X3, bins=range(100), density=True)
26  axs[1, 0].plot(gaussData(mu, sigma / sqrt(12)))
27  axs[1, 0].set_title("n = 12")
28
29  axs[1, 1].hist(X4, bins=range(100), density=True)
30  axs[1, 1].plot(gaussData(mu, sigma / sqrt(24)))
31  axs[1, 1].set_title("n = 24")

```



O Teorema Central do Limite (TCL) estabelece que a distribuição das médias de amostras aleatórias tende a uma distribuição normal, independentemente da forma da distribuição da população original, desde que o tamanho da amostra seja suficientemente grande ($n \geq 30$, em geral).

Ele é fundamental para a inferência estatística, pois permite realizar cálculos de probabilidades e construir intervalos de confiança assumindo a normalidade das médias amostrais.

12.1 Desafio

1. Um hospital está analisando o tempo de atendimento dos pacientes no pronto atendimento. Observou-se que:

- A maior parte dos atendimentos é rápida, variando entre **5 e 20 minutos**
- Alguns casos são mais complexos e demoram mais, ficando entre **40 e 60 minutos**
- Esses atendimentos mais longos são menos frequentes

Com o objetivo de melhorar o planejamento e a organização do atendimento, o hospital deseja entender melhor o comportamento dos tempos médios de atendimento.

Para isso, você foi contratado para realizar uma simulação e analisar os dados.

Utilizar simulação para:

- Estimar o tempo médio de atendimento

- Analisar a variabilidade dos dados
- Observar o comportamento da média em grupos de pacientes

a) Simule **10.000 atendimentos individuais**.

b) A partir desses dados, calcule:

- a média
- o desvio padrão

c) O tempo médio de atendimento está mais próximo de **10, 20 ou 30 minutos**?

2. Agora considere grupos de pacientes. Calcule a média de atendimento para diferentes tamanhos de grupo. Construa gráficos (plt.hist) e analise:

- Qual distribuição parece mais “bagunçada”?
- Qual começa a se aproximar de uma curva normal (formato de sino)?

3. Após suas análises, considere que a média dos grupos grandes pode ser aproximada por uma distribuição normal.

Suponha que:

- média ≈ 18 minutos
- desvio padrão ≈ 4 minutos

Pergunta:

Qual a probabilidade de que a média de atendimento de um grupo de pacientes seja **maior que 22 minutos**?

Dica: Utilize a biblioteca abaixo para consultar a tabela Z

```
from scipy.stats import norm
```

```
z = calcule Z
```

```
prob = 1 - norm.cdf(z)
```

Resolução